

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ

ESCUELA DE POSGRADO

MAESTRÍA EN ECONOMÍA

SEMESTRE 2018 – I

CURSO: ECONOMETRÍA INTERMEDIA

MÓDULO 4: Series de Tiempo

PROFESOR: JORGE RODAS

JEFE DE PRÁCTICA: MARTÍN VILLARÁN SALA / CARLOS RODRIGUEZ

PRÁCTICA DIRIGIDA 1

- 1) Genere las siguientes series de tiempo (en un program en Eviews) de tal manera que todas sean estacionarias. Obtenga los gráficos, funciones de autocorrelación y funciones de autocorrelación parcial de cada serie de tiempo. Comente si estas funciones se asemejan a las funciones teóricas (las vistas en clase teórica).

Solución:

Como primer paso, definimos el tamaño de la muestra (mil períodos) y fijamos una semilla para la generación de números pseudo-aleatorios, con la finalidad de que los resultados sean replicables:

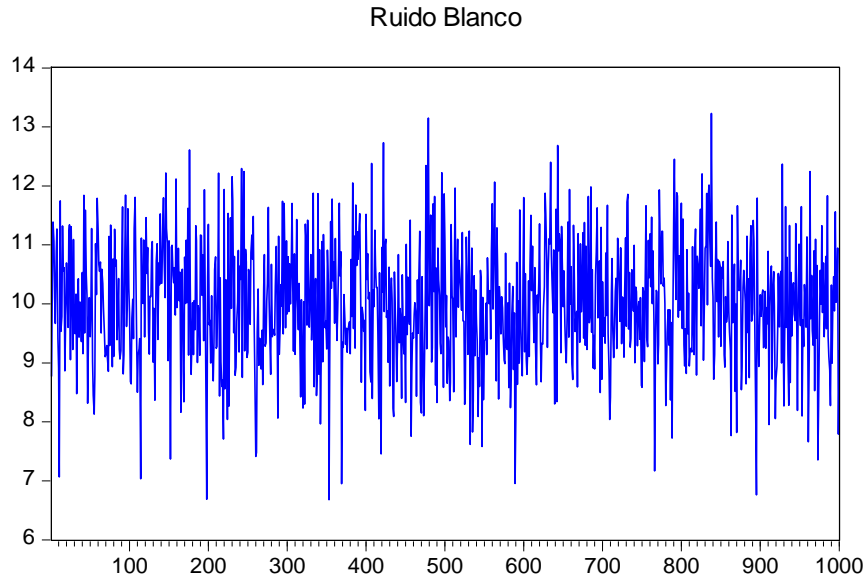
```
create u 1 1000  
rndseed 1
```

1.a) “ruido blanco” con constante

El ruido blanco lo creamos con el comando “nrnd” que genera números aleatorios con distribución normal, con media cero y varianza uno. Asimismo le incluimos una constante igual a 10.

```
smpl @all  
genr rb_c=10+nrnd  
freeze(rb_c_correl) rb_c.correl(24)  
freeze(rb_c_histog) rb_c.hist
```

A continuación se presenta un gráfico de la serie ruido blanco (con intercepto igual a 10), generada en Eviews. Como se puede apreciar, la serie dado que es estacionario, presenta su principal característica: rápida reversión a la media.



Asimismo, otra forma de analizar la estacionariedad de la serie simulada, ruido blanco, es a través del correlograma. Las funciones de autocorrelación y autocorrelación parcial se muestran a continuación, donde se puede comprobar la estacionariedad del proceso ruido blanco con constante:

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob
		1 0.022	0.022	0.4965	0.481
		2 0.042	0.041	2.2621	0.323
		3 0.084	0.083	9.3881	0.025
		4 -0.03...	-0.03...	10.521	0.033
		5 0.030	0.025	11.406	0.044
		6 -0.05...	-0.05...	13.908	0.031
		7 -0.00...	-0.00...	13.974	0.052
		8 0.044	0.043	15.957	0.043
		9 0.029	0.039	16.819	0.052
		1... -0.03...	-0.04...	18.283	0.050
		1... -0.00...	-0.00...	18.284	0.075
		1... -0.03...	-0.03...	19.321	0.081
		1... 0.005	0.014	19.343	0.113
		1... 0.007	0.010	19.397	0.150
		1... 0.040	0.052	21.019	0.136
		1... -0.02...	-0.04...	21.839	0.148
		1... 0.064	0.060	25.963	0.075
		1... 0.042	0.033	27.755	0.066
		1... -0.04...	-0.03...	29.643	0.057
		2... 0.049	0.036	32.113	0.042
		2... -0.00...	0.007	32.113	0.057
		2... -0.01...	-0.01...	32.281	0.073
		2... -0.02...	-0.03...	32.741	0.086
		2... -0.02...	-0.01...	33.399	0.096

Como se puede apreciar en el gráfico anterior, tanto la función de autocorrelación, como la función de autocorrelación parcial no presentan barras que salgan de las bandas de confianza, por lo tanto no son estadísticamente significativos. Es decir, las

autocorrelaciones de orden 1 hasta orden 24 son igual a 0. Asimismo, las autocorrelaciones parciales de orden 1 hasta orden 24, también son igual a 0.

Cabe mencionar que tanto la función de autocorrelación simple, como la función de autocorrelación parcial se asemejan a las funciones teóricas vistas en clase, pues precisamente éstas provienen de series que hemos simulado en la computadora, las cuales son idénticas a las teóricas.

1.b) AR(3)


En este caso creamos procesos AR(3) considerando dos opciones (raíces positivas y raíces negativas). En ambos casos el periodo inicial se ha creado con el comando "rnd" que genera números aleatorios en el intervalo [0,1] con distribución uniforme.

AR(3) con coeficientes positivos



```
smpl @first @first+2  
series ar3_a=0  
smpl @first+3 @last  
series ar3_a=0.20*ar3_a(-1)+0.20*ar3_a(-2)+0.20*ar3_a(-3)+nrnd  
freeze(ar3_a_correl) ar3_a.correl(24)  
freeze(ar3_a_histog) ar3_a.hist
```

A continuación se presenta un gráfico de la serie AR(3) generada en Eviews. Como se puede apreciar, la serie dado que es estacionario, presenta su principal característica: reversion a la media, aunque a comparación del ruido blanco gaussiano, esta vez la serie tarda un poco más en retornar a su media muestral.

Serie Simulada AR(3)



Como sabemos, en los procesos $AR(p)$, el rápido decaimiento (convergencia hacia cero) de la función de autocorrelación simple nos indica que estamos trabajando con series autorregresivas estacionarias; por su parte, la función de autocorrelación parcial nos indicará el orden del componente autorregresivo “p”. En este caso, vemos que la función de autocorrelación parcial presenta 3 barras que se salen de la banda de confianza, lo que nos indica que nos encontramos con una serie $AR(3)$.

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob
		1 0.356	0.356	126.74	0.000
		2 0.333	0.237	237.97	0.000
		3 0.354	0.217	363.42	0.000
		4 0.203	-0.01...	404.65	0.000
		5 0.154	-0.03...	428.45	0.000
		6 0.114	-0.03...	441.59	0.000
		7 0.066	-0.02...	445.93	0.000
		8 0.066	0.022	450.38	0.000
		9 0.020	-0.02...	450.76	0.000
		1... 0.041	0.031	452.45	0.000
		1... 0.036	0.015	453.80	0.000
		1... 0.033	0.019	454.88	0.000
		1... 0.016	-0.02...	455.15	0.000
		1... 0.033	0.014	456.25	0.000
		1... 0.014	-0.01...	456.46	0.000
		1... 0.009	-0.00...	456.54	0.000
		1... 0.006	-0.00...	456.57	0.000
		1... 0.003	-0.00...	456.58	0.000
		1... -0.01...	-0.01...	456.71	0.000
		2... -0.04...	-0.05...	458.76	0.000
		2... -0.04...	-0.02...	460.78	0.000
		2... -0.01...	0.029	461.01	0.000
		2... -0.01...	0.027	461.30	0.000
		2... -0.00...	0.024	461.30	0.000

Cabe mencionar que tanto la función de autocorrelación simple, como la función de autocorrelación parcial para la serie $AR(3)$ se asemejan a las funciones teóricas vistas en clase, pues precisamente éstas provienen de series que hemos simulado en la computadora, las cuales son idénticas a las teóricas. Sería distinto si tuviésemos una serie empírica, por ejemplo, el PBI de Perú y tratásemos de identificar el orden del componente autorregresivo $AR(p)$; en dicho caso, si concluyéramos que la serie del PBI peruano se comporta como un $AR(3)$, esto sería solo una aproximación, y los gráficos tanto de la función de autocorrelación simple como de la función de autocorrelación parcial no serían idénticos a los de un $AR(3)$ teórico o simulado en una computadora.

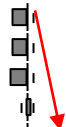

AR(3) con coeficientes negativos

```
smpl @first @first+2
series ar3_b=0
```

```

smpl @first+3 @last
series ar3_b=-0.2*ar3_b(-1)-0.2*ar3_b(-2)-0.2*ar3_b(-3)+nrnd
freeze(ar3_b_correl) ar3_b.correl(24)
freeze(ar3_b_histog) ar3_b.hist

```

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob
		1 -0.13...	-0.13...	18.604	0.000
		2 -0.13...	-0.15...	36.218	0.000
		3 -0.14...	-0.19...	56.927	0.000
		4 0.040	-0.04...	58.557	0.000
		5 0.039	-0.01...	60.111	0.000
		6 -0.03...	-0.06...	61.465	0.000
		7 -0.01...	-0.03...	61.733	0.000
		8 -0.00...	-0.02...	61.819	0.000
		9 0.017	-0.01...	62.104	0.000
		1... 0.026	0.017	62.807	0.000
		1... 0.002	0.008	62.810	0.000
		1... -0.02...	-0.01...	63.515	0.000
		1... 0.025	0.029	64.166	0.000
		1... 0.019	0.025	64.549	0.000
		1... -0.04...	-0.03...	66.392	0.000
		1... 0.004	0.008	66.407	0.000
		1... 0.026	0.027	67.109	0.000
		1... 0.027	0.026	67.838	0.000
		1... -0.03...	-0.00...	68.749	0.000
		2... -0.02...	-0.01...	69.285	0.000
		2... 0.030	0.025	70.196	0.000
		2... -0.03...	-0.04...	71.788	0.000
		2... 0.003	-0.01...	71.795	0.000
		2... 0.033	0.030	72.903	0.000

1.c) MA (3)

De manera similar al caso anterior, en los procesos MA(3) considerando dos opciones para las raíces (raíces positivas y raíces negativas). En ambos casos el periodo inicial se ha creado con el comando "nrnd" pues necesitamos un ruido blanco con distribución normal, con media cero y varianza σ^2

MA(3) con coeficientes positivos


```

smpl @all
series rb1=nrnd
series ma3_a=0
smpl @first+3 @last
series ma3_a=rb1+0.2*rb1(-1)+0.2*rb1(-2)+0.2*rb1(-3)
freeze(ma3_a_correl) ma3_a.correl(24)
freeze(ma3_a_histog) ma3_a.hist

```

A continuación se presenta un gráfico de la serie simulada MA(3), generada en Eviews. En el gráfico de la serie, también podemos apreciar que existe reversión a la media muestral. Esto se debe a que las tres raíces del proceso de medias móviles son menores a 1, por lo tanto, nuestro proceso MA(3) se dice que es invertible.

Serie Simulada MA(3)



Contrariamente a los procesos Autorregresivos de orden(p), los procesos de Medias Móviles de orden (q) presentan un comportamiento inverso en la función de autocorrelación simple (ACF) y la función de autocorrelación parcial (PACF). Es decir, en un proceso MA(q) el orden del proceso, q, nos lo dará la función de autocorrelación simple, mientras que la función de autocorrelación parcial debe decaer hacia cero, como señal de que la serie es estacionaria.

En el siguiente gráfico podemos ver que la función de autocorrelación simple presenta tres barras que salen de las bandas de confianza, lo que indica que estamos trabajando con una serie MA(3).

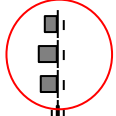















































Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob
		1 0.212	0.212	44.744	0.000
		2 0.222	0.186	94.151	0.000
		3 0.166	0.095	121.64	0.000
		4 -0.00...	-0.10...	121.71	0.000
		5 0.011	-0.02...	121.83	0.000
		6 0.031	0.043	122.81	0.000
		7 0.047	0.062	125.01	0.000
		8 0.035	0.007	126.25	0.000
		9 -0.01...	-0.05...	126.41	0.000
		1... -0.00...	-0.02...	126.49	0.000
		1... -0.01...	0.006	126.69	0.000
		1... -0.07...	-0.06...	132.97	0.000
		1... -0.01...	0.012	133.14	0.000
		1... 0.008	0.034	133.20	0.000
		1... -0.02...	-0.01...	133.82	0.000
		1... -0.01...	-0.03...	134.16	0.000
		1... -0.02...	-0.01...	134.77	0.000
		1... -0.01...	0.011	135.11	0.000
		1... -0.02...	-0.00...	135.74	0.000
		2... -0.01...	0.000	135.84	0.000
		2... -0.03...	-0.04...	137.27	0.000
		2... -0.00...	0.007	137.36	0.000
		2... -0.03...	-0.01...	138.72	0.000
		2... -0.03...	-0.02...	140.12	0.000

MA(3) con coeficientes negativos

```

smpl @all
series rb1=nrnd
series ma3_b=0
smpl @first+3 @last
series ma3_b=rb1-0.2*rb1(-1)-0.2*rb1(-2)-0.2*rb1(-3)
freeze(ma3_b_correl) ma3_b.correl(24)
freeze(ma3_b_histog) ma3_b.hist

```

Autocorrelation	Partial Correlation	AC	PAC	Q-Stat	Prob
		1 -0.11...	-0.11...	12.229	0.000
		2 -0.16...	-0.17...	38.858	0.000
		3 -0.14...	-0.19...	60.696	0.000
		4 0.022	-0.06...	61.202	0.000
		5 -0.02...	-0.10...	61.718	0.000
		6 -0.07...	-0.14...	66.735	0.000
		7 -0.00...	-0.08...	66.764	0.000
		8 0.026	-0.05...	67.445	0.000
		9 0.015	-0.05...	67.687	0.000
		1... 0.023	-0.01...	68.225	0.000
		1... -0.01...	-0.03...	68.356	0.000
		1... -0.02...	-0.05...	69.018	0.000
		1... 0.000	-0.02...	69.018	0.000
		1... 0.041	0.016	70.720	0.000
		1... -0.05...	-0.06...	73.641	0.000
		1... 0.007	-0.00...	73.686	0.000
		1... 0.022	0.003	74.168	0.000
		1... 0.052	0.035	76.961	0.000
		1... -0.02...	-0.00...	77.590	0.000
		2... -0.02...	-0.00...	78.398	0.000
		2... 0.023	0.027	78.918	0.000
		2... -0.01...	-0.00...	79.023	0.000
		2... 0.036	0.052	80.329	0.000
		2... -0.02...	0.008	80.763	0.000

1.d) ARMA(2,1)


```

smpl @all
series rb2=nrnd
series ma1=0
smpl @first+1 @last
series ma1=rb2+0.20*rb2(-1)
smpl @first @first+1
series arma21=rnd
smpl @first+2 @last
series arma21=0.2*arma21(-1)+0.2*arma21(-2)+ma1
freeze(arma21_correl) arma21.correl(24)
freeze(arma21_histog) arma21.hist

















































```

A continuación se muestra el gráfico de la serie simulada ARMA(2,1). Al igual que los casos anteriores, dado que la serie es estacionaria, en el gráfico se podrá apreciar que existe reversión a la media.

Serie Simulada ARMA(2,1)



El correlograma de la serie ARMA(2,1) muestra decaimiento tanto de la función de autocorrelación simple (ACF) como de la función de autocorrelación parcial (PACF). Para identificar el orden de “p” nos fijamos en la función de autocorrelación parcial, mientras que para identificar el orden de “q” nos debemos fijar cuántas barras salen de la banda de confianza en la función de autocorrelación simple.

Autocorrelation	Partial Correlation		AC	PAC	Q-Stat	Prob
		1	0.467	0.467	218.03	0.000
		2	0.311	0.119	314.75	0.000
		3	0.149	-0.04...	337.02	0.000
		4	0.092	0.011	345.53	0.000
		5	0.074	0.033	351.04	0.000
		6	0.027	-0.03...	351.77	0.000
		7	0.028	0.015	352.56	0.000
		8	0.011	-0.00...	352.68	0.000
		9	0.000	-0.01...	352.68	0.000
		1...	0.014	0.021	352.88	0.000
		1...	0.033	0.031	353.98	0.000
		1...	0.057	0.035	357.30	0.000
		1...	0.033	-0.01...	358.39	0.000
		1...	0.036	0.013	359.67	0.000
		1...	0.021	-0.00...	360.13	0.000
		1...	0.037	0.026	361.52	0.000
		1...	0.038	0.013	363.03	0.000
		1...	0.050	0.024	365.53	0.000
		1...	0.042	0.003	367.36	0.000
		2...	0.019	-0.01...	367.71	0.000
		2...	0.008	-0.00...	367.78	0.000
		2...	0.010	0.010	367.89	0.000
		2...	0.044	0.044	369.85	0.000
		2...	0.039	0.001	371.39	0.000

A modo de resumen, presentamos la siguiente tabla:

Modelo	Función de Autocorrelación (ACF)	Función de Autocorrelación Parcial (PACF)
Ruido Blanco	Todas las autocorrelaciones son 0	Todas las autocorrelaciones parciales son 0
AR(3)	Decaen rápidamente después del tercer rezago.	Los tres primeros períodos hay barras que salen de la banda de confianza.
MA(3)	Barras positivas que salen de las bandas de confianza hasta el rezago 3.	Decaen rápidamente después del tercer rezago.
ARMA(2,1)	Decae luego del rezago 1.	Decae luego del rezago 2.

Si se compara con lo trabajado en clase, en los cuatro modelos anteriormente presentados, se puede observar que las series se comportan tal como lo esperado en la Teoría.

2) Metodología Box-Jenkins

Seleccione la SERIE 3 del workfile “**Series simuladas.wf1**”.y aplique la metodología Box-Jenkins para encontrar el modelo ARMA(p,q) que mejor se ajusta a los datos. Para ello deberá seguir cada uno de los pasos de la metodología. Si la serie elegida no es estacionaria deberá hacer las transformaciones necesarias hasta encontrar una serie estacionaria. Debe elegir por lo menos tres modelos tentativos en cada caso y luego de aplicar los criterios adecuados, elegir al mejor modelo.

Solución:

La metodología de Box-Jenkins consta, en general, de 4 pasos, los cuales se explican a continuación.

Paso 1: Identificación

Como primer paso de la metodología Box Jenkins, debemos encontrar los valores apropiados para p y q. Para ello, debemos analizar el correlograma y el correlograma parcial de la serie en cuestión.

Debemos hacer también un análisis de Raíz Unitaria para estar seguros de que la serie es estacionaria; si la serie es integrada de orden 1, entonces debemos diferenciar la serie, es decir, realizar una transformación de la misma a fin de que trabajemos con una serie $I(0)$.

Paso 2: Estimación

Como resultado de la primera etapa, tendremos una lista de "N" modelos alternativos que podrían servir para identificar el orden de "p" y "q". Por ejemplo, si creemos que los modelos apropiados para la serie analizada podrían ser:

1. ARMA (2,3)
2. ARMA (4,5)

Con esta lista de candidatos de posibles modelos, debemos realizar una estimación por MCO de cada uno de ellos, utilizando como input la serie en cuestión.

Paso 3: Diagnóstico

Luego de la estimación, debemos realizar un diagnóstico de cada modelo, es decir, debemos analizar que se cumpla la homocedasticidad de los residuos, no autocorrelación, estabilidad de los parámetros, normalidad de los residuos. Asimismo, debemos analizar que cada uno de los

coeficientes estimados sea estadísticamente significativo. Además, los coeficientes estimados deben ser significativos globalmente, para ello analizamos el test F.

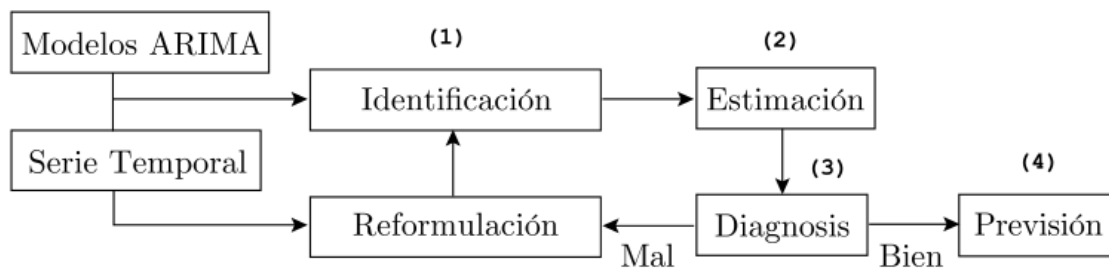
Por último, es importante analizar los criterios de información AIC y BIC, y elegir aquel modelo que tenga el menor AIC y/o el menor BIC.

Paso 4: Proyección (Forecast)

Hacer un forecast usando el modelo o modelos seleccionados como aquellos que mejor se ajustan a los datos.

Paso 1: Identificación

Secuencia de Pasos para aplicar la Metodología Box-Jenkins



ANÁLISIS GRÁFICO

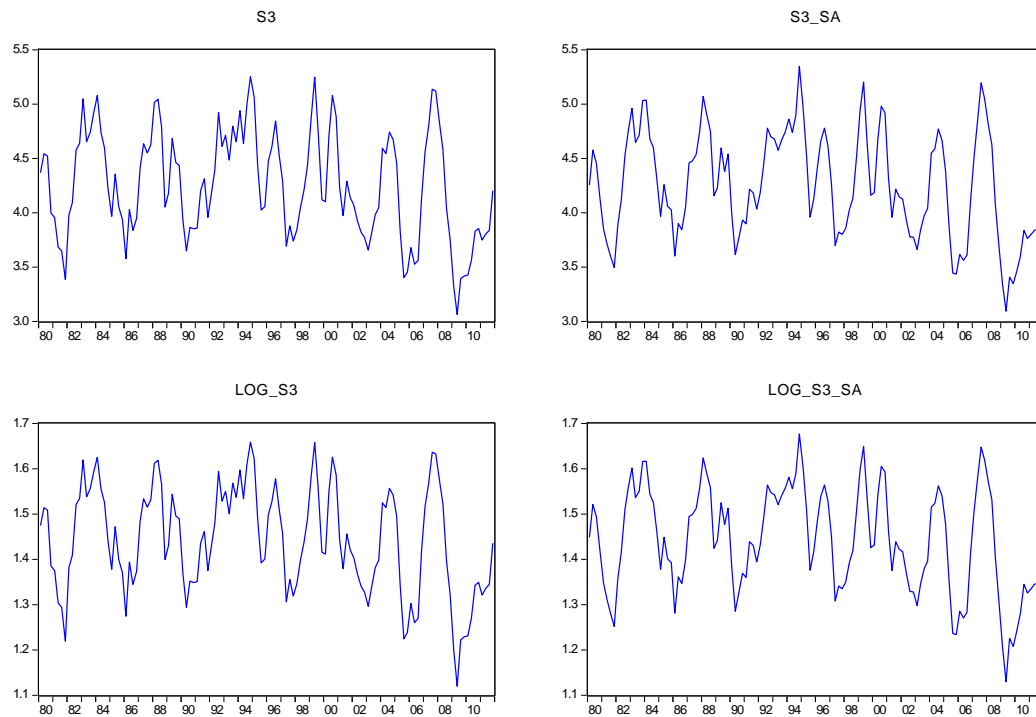
El Gráfico 1 presenta los gráficos de la serie S3 original además de la serie desestacionalizada (utilizando el filtro ARIMA X12), la serie suavizada (mediante logaritmos) y la combinación de estas últimas dos transformaciones.

A partir de este análisis notamos que las series desestacionalizadas no presentan un comportamiento significativamente distinto al de las series originales, esto sugeriría que desde un principio las series originales no presentaban un componente estacional.

El suavizamiento si llega a tener un efecto en la escala de las series debido a la transformación de la función logarítmica.

Es importante notar que la serie parece no seguir una tendencia. Y, debido a que su media no es cero, presentaría un intercepto. Asimismo, no parece haber evidencia de quiebre estructural en el horizonte analizado.

GRÁFICO 1




El Gráfico 2 presenta los histogramas de la serie S3 y sus demás transformaciones. Se busca saber si la serie presenta el comportamiento de una distribución normal para así concluir que esta es estacionaria.

La media de la serie no se acerca a 0, lo que puede ser evidencia de un intercepto en la serie. La kurtosis de la serie no se encuentra cercana a 3, lo que implica que esta no se estaría comportando como una normal. Asimismo, se puede notar que la serie presenta una asimetría cercana a 0, lo que sí sería evidencia de que se comporta como una normal.

Finalmente, para un análisis más formal, analizaremos el test de Jarque-Bera. En todos los casos, el test NO RECHAZA la hipótesis nula de Normalidad.

GRÁFICO 2



TESTS DE RAÍZ UNITARIA

¿La serie es estacionaria?

Para contestar esta pregunta de manera formal utilizaremos varios test de raíz unitaria, como son:

- Aumented Dickey-Fuller (ADF)
- Phillips-Perron (PP)
- Kwiatkowski-Phillips-Schmidt-Shin (KPSS)
- Elliott-Rothenberg-Stock (ERS o DF-GLS)
- NG-PERRON

En todos los test utilizados en esta sección se ha especificado la presencia de un intercepto.

AUMENTED DICKEY-FULLER (ADF)

Null Hypothesis: S3 has a unit root

Exogenous: Constant

Lag Length: 0 (Automatic - based on Modified AIC, maxlag=12)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-3.674128	0.0056
Test critical values: 1% level	-3.482453	
5% level	-2.884291	

10% level -2.578981

*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation

Dependent Variable: D(S3)

Method: Least Squares

Date: 06/22/18 Time: 10:12

Sample (adjusted): 1980Q2 2011Q4

Included observations: 127 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
S3(-1)	-0.194771	0.053011	-3.674128	0.0004
C	0.827606	0.227129	3.643776	0.0004
-				
R-squared	0.097468	Mean dependent var	0.001317	
Adjusted R-squared	0.090248	S.D. dependent var	0.309728	
S.E. of regression	0.295422	Akaike info criterion	0.414797	
Sum squared resid	10.90925	Schwarz criterion	0.459588	
Log likelihood	-24.33963	Hannan-Quinn criter.	0.432995	
F-statistic	13.49922	Durbin-Watson stat	1.485838	
Prob(F-statistic)	0.000353			

PHILLIPS PERRON (PP)

Null Hypothesis: S3 has a unit root

Exogenous: Constant

Bandwidth: 2 (Newey-West automatic) using Bartlett kernel

	Adj. t-Stat	Prob.*
Phillips-Perron test statistic	-4.177574	0.0011
Test critical values: 1% level	-3.482453	
5% level	-2.884291	
10% level	-2.578981	

*MacKinnon (1996) one-sided p-values.

Residual variance (no correction)	0.085900
HAC corrected variance (Bartlett kernel)	0.116571

Phillips-Perron Test Equation

Dependent Variable: D(S3)
Method: Least Squares
Date: 06/22/18 Time: 10:12
Sample (adjusted): 1980Q2 2011Q4
Included observations: 127 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
S3(-1)	-0.194771	0.053011	-3.674128	0.0004
C	0.827606	0.227129	3.643776	0.0004

R-squared	0.097468	Mean dependent var	0.001317
Adjusted R-squared	0.090248	S.D. dependent var	0.309728
S.E. of regression	0.295422	Akaike info criterion	0.414797
Sum squared resid	10.90925	Schwarz criterion	0.459588
Log likelihood	-24.33963	Hannan-Quinn criter.	0.432995
F-statistic	13.49922	Durbin-Watson stat	1.485838
Prob(F-statistic)	0.000353		

KWIAWKOWSKI-PHILLIPS-SCHMIDT-SHIN (KPSS)

Null Hypothesis: S3 is stationary
Exogenous: Constant
Bandwidth: 7 (Newey-West automatic) using Bartlett kernel

	LM-Stat.
Kwiatkowski-Phillips-Schmidt-Shin test statistic	0.302263
Asymptotic critical values*:	
1% level	0.739000
5% level	0.463000
10% level	0.347000

*Kwiatkowski-Phillips-Schmidt-Shin (1992, Table 1)

Residual variance (no correction)	0.242648
HAC corrected variance (Bartlett kernel)	0.853568

KPSS Test Equation
Dependent Variable: S3
Method: Least Squares
Date: 06/22/18 Time: 10:12
Sample: 1980Q1 2011Q4
Included observations: 128

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	4.255469	0.043711	97.35568	0.0000
R-squared	0.000000	Mean dependent var	4.255469	
Adjusted R-squared	0.000000	S.D. dependent var	0.494528	
S.E. of regression	0.494528	Akaike info criterion	1.437357	
Sum squared resid	31.05890	Schwarz criterion	1.459639	
Log likelihood	-90.99085	Hannan-Quinn criter.	1.446410	
Durbin-Watson stat	0.389183			

ELLIOTT-ROTHENBERG-STOCK DF-GLS

Null Hypothesis: S3 has a unit root

Exogenous: Constant

Lag Length: 0 (Automatic - based on Modified AIC, maxlag=12)

	t-Statistic
Elliott-Rothenberg-Stock DF-GLS test statistic	-3.633398
Test critical values: 1% level	-2.583298
5% level	-1.943364
10% level	-1.615050

*MacKinnon (1996)

DF-GLS Test Equation on GLS Detrended Residuals

Dependent Variable: D(GLSRESID)

Method: Least Squares

Date: 06/22/18 Time: 10:12

Sample (adjusted): 1980Q2 2011Q4

Included observations: 127 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
GLSRESID(-1)	-0.189916	0.052270	-3.633398	0.0004
R-squared	0.094821	Mean dependent var	0.001317	
Adjusted R-squared	0.094821	S.D. dependent var	0.309728	
S.E. of regression	0.294678	Akaike info criterion	0.401977	
Sum squared resid	10.94124	Schwarz criterion	0.424372	
Log likelihood	-24.52555	Hannan-Quinn criter.	0.411076	
Durbin-Watson stat	1.488078			

NG-PERRON

Null Hypothesis: S3 has a unit root

Exogenous: Constant

Lag length: 0 (Spectral GLS-detrended AR based on Modified AIC, maxlag=12)

Sample: 1980Q1 2011Q4

Included observations: 128

	MZa	MZt	MSB	MPT
Ng-Perron test statistics	-21.8262	-3.30097	0.15124	1.13141
Asymptotic critical values*:				
1%	-13.8000	-2.58000	0.17400	1.78000
5%	-8.10000	-1.98000	0.23300	3.17000
10%	-5.70000	-1.62000	0.27500	4.45000

*Ng-Perron (2001, Table 1)

HAC corrected variance (Spectral GLS-detrended AR)	0.086152
--	----------


Cabe resaltar que existen otros tipos de test de raíz unitaria que tienen en cuenta en su análisis la presencia de quiebres estructurales así como de estacionalidad. No se han utilizado estos test debido a que, como concluimos anteriormente, la serie parece no contener un componente estacional ni hemos encontrado indicios de quiebre estructural.

Del análisis de los test de raíz unitaria podemos concluir que la serie es estacionaria.

PROPUESTA DE MODELOS CANDIDATO

Dado que hemos hallado que la serie es estacionaria, pasamos a proponer los posibles procesos que podrían explicar el comportamiento de esta serie.

GRÁFICO 3



Del Gráfico 3 notamos que ambas funciones, la de autocorrelación y la de autocorrelación parcial, presentan valores que decaen en intensidad. A partir de la función de autocorrelación parcial notamos la posible presencia de componentes AR de grado 2. Mientras que a partir de la función de autocorrelación notamos la posible presencia de componentes MA hasta de grado 3.

Se proponen los siguientes modelos “candidatos”:

- Modelo 1: ARMA(0,1)
- Modelo 2: ARMA(0,3)
- Modelo 3: ARMA(1,0)
- Modelo 4: ARMA(2,0)
- Modelo 5: ARMA(3,0)
- Modelo 6: ARMA(1,1)
- Modelo 7: ARMA(2,3)
- Modelo 8: ARMA(3,3)
- Modelo 9: ARMA(4,3)
- Modelo 10: ARMA(2,4)

Para todos los modelos propuestos se especificó un intercepto.

Para elegir el modelo que explique de mejor forma el comportamiento de la serie analizada tendremos en cuenta: el análisis gráfico y de correlogramas para proponer distintos modelos “candidato”; asimismo, analizaremos la significancia conjunta e individual de los componentes MA o AR especificados. Se tendrá en cuenta la bondad de ajuste del modelo y, en cuanto a los residuos, se esperará que estos sean bien comportados; es decir, se analizará la presencia de

perturbaciones esféricas y comportamiento normal de los residuos para que los test de significancia sean válidos.

Paso 2: Estimación

- Estimación Modelo 1: ARMA(0,1)

Dependent Variable: S3
 Method: Least Squares
 Date: 06/22/18 Time: 10:46
 Sample: 1980Q1 2011Q4
 Included observations: 128
 Convergence achieved after 11 iterations
 MA Backcast: 1979Q4

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	4.256012	0.051763	82.22073	0.0000
MA(1)	0.647706	0.067618	9.578918	0.0000
R-squared	0.486072	Mean dependent var	4.255469	
Adjusted R-squared	0.481993	S.D. dependent var	0.494528	
S.E. of regression	0.355925	Akaike info criterion	0.787310	
Sum squared resid	15.96203	Schwarz criterion	0.831873	
Log likelihood	-48.38782	Hannan-Quinn criter.	0.805416	
F-statistic	119.1706	Durbin-Watson stat	1.186691	
Prob(F-statistic)	0.000000			
Inverted MA Roots	-.65			

El modelo ARMA(0,1) presenta sinificancia individual y conjunta de sus parámetros. Pero es posible que exista presencia de un mayor grado de componentes MA. Asimismo, el modelo presenta una bondad de ajuste relativamente baja, y es posible que presente autocorrelación.

Prueba de Heterocedasticidad

Heteroskedasticity Test: White

F-statistic	2.56E+24	Prob. F(9,118)	0.0000
Obs*R-squared	128.0000	Prob. Chi-Square(9)	0.0000
Scaled explained	80.00248	Prob. Chi-Square(9)	0.0000

SS

Prueba de Autocorrelación

Breusch-Godfrey Serial Correlation LM Test:

F-statistic	39.37364	Prob. F(2,124)	0.0000
Obs*R-squared	49.71533	Prob. Chi-Square(2)	0.0000

- **Estimación Modelo 2: ARMA(0,3)**

Dependent Variable: S3
Method: Least Squares
Date: 06/22/18 Time: 10:46
Sample: 1980Q1 2011Q4
Included observations: 128
Convergence achieved after 16 iterations
MA Backcast: 1979Q2 1979Q4

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	4.257269	0.074566	57.09416	0.0000
MA(1)	1.063208	0.088418	12.02480	0.0000
MA(2)	0.782116	0.109485	7.143611	0.0000
MA(3)	0.183694	0.088678	2.071479	0.0404
R-squared	0.689515	Mean dependent var	4.255469	
Adjusted R-squared	0.682003	S.D. dependent var	0.494528	
S.E. of regression	0.278871	Akaike info criterion	0.314614	
Sum squared resid	9.643335	Schwarz criterion	0.403740	
Log likelihood	-16.13528	Hannan-Quinn criter.	0.350826	
F-statistic	91.79154	Durbin-Watson stat	1.915821	
Prob(F-statistic)	0.000000			
Inverted MA Roots	-.34	-.36+.64i	-.36-.64i	

Como alternativa al modelo ARMA(0,1) y para investigar la presencia de un mayor grado del componente MA, se ha decidido postular el modelo ARMA(0,3). Este modelo presenta parámetros significativos de forma individual y conjunta. La bondad de ajusta ha mejorado en

comparación con el modelo anterior. Asimismo, la presencia de autocorrelación parece haber desaparecido.

En conclusión, la serie parece contener un componente MA de grado, al menos, superior a 1.

- **Estimación Modelo 3: ARMA(1,0)**

Dependent Variable: S3
Method: Least Squares
Date: 06/22/18 Time: 10:46
Sample (adjusted): 1980Q2 2011Q4
Included observations: 127 after adjustments
Convergence achieved after 3 iterations

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	4.249127	0.134604	31.56765	0.0000
AR(1)	0.805229	0.053011	15.18973	0.0000
R-squared	0.648608	Mean dependent var	4.254572	
Adjusted R-squared	0.645797	S.D. dependent var	0.496382	
S.E. of regression	0.295422	Akaike info criterion	0.414797	
Sum squared resid	10.90925	Schwarz criterion	0.459588	
Log likelihood	-24.33963	Hannan-Quinn criter.	0.432995	
F-statistic	230.7279	Durbin-Watson stat	1.485838	
Prob(F-statistic)	0.000000			
Inverted AR Roots	.81			

Con el modelo ARMA(1,0) analizamos la pertinencia de especificar un componente AR en los siguientes candidatos para describir el comportamiento de la serie S3.

Los parámetros del modelo ARMA(1,0) son significativos de forma individual y conjunta, pero parece presentar autocorrelación. Por lo que será razonable aumentar el grado del componente AR y analizar su pertinencia.

- **Estimación Modelo 4: ARMA(2,0)**

Dependent Variable: S3
Method: Least Squares
Date: 06/22/18 Time: 10:46
Sample (adjusted): 1980Q3 2011Q4
Included observations: 126 after adjustments
Convergence achieved after 3 iterations

Variable	Coefficient	Std. Error	t-Statistic	Prob.
----------	-------------	------------	-------------	-------

C	4.249688	0.097633	43.52702	0.0000
AR(1)	1.059910	0.085722	12.36447	0.0000
AR(2)	-0.317336	0.085950	-3.692081	0.0003
<hr/>				
R-squared	0.683948	Mean dependent var	4.252280	
Adjusted R-squared	0.678809	S.D. dependent var	0.497689	
S.E. of regression	0.282059	Akaike info criterion	0.330119	
Sum squared resid	9.785527	Schwarz criterion	0.397649	
Log likelihood	-17.79747	Hannan-Quinn criter.	0.357554	
F-statistic	133.0883	Durbin-Watson stat	2.064078	
Prob(F-statistic)	0.000000			
<hr/>				
Inverted AR Roots	.53-.19i	.53+.19i		

El modelo ARMA(2,0) presenta parámetros significativos individual como conjuntamente. Tiene una buena bondad de ajuste y no presenta autocorrelación. A partir de este modelo podemos concluir que será pertinente especificar un componente AR de, digamos, grado superior a 1 para describir el comportamiento de la serie S3.

- **Estimación Modelo 5: ARMA(3,0)**

Dependent Variable: S3
Method: Least Squares
Date: 06/22/18 Time: 10:46
Sample (adjusted): 1980Q4 2011Q4
Included observations: 125 after adjustments
Convergence achieved after 3 iterations

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	4.251665	0.088346	48.12512	0.0000
AR(1)	1.024774	0.090634	11.30668	0.0000
AR(2)	-0.198893	0.128948	-1.542426	0.1256
AR(3)	-0.112089	0.090767	-1.234909	0.2193
R-squared	0.687142	Mean dependent var	4.250124	
Adjusted R-squared	0.679385	S.D. dependent var	0.499101	
S.E. of regression	0.282605	Akaike info criterion	0.341943	
Sum squared resid	9.663730	Schwarz criterion	0.432449	
Log likelihood	-17.37144	Hannan-Quinn criter.	0.378711	
F-statistic	88.58569	Durbin-Watson stat	1.947897	
Prob(F-statistic)	0.000000			
Inverted AR Roots	.63+.31i	.63-.31i	-.23	

Con el modelo ARMA(3,0) notamos que al agregar un componente AR más al modelo ARMA(2,0) los parámetros comienzan a perder significancia y el modelo comienza a presentar inconsistencias (como la posible presencia de autocorrelación).

- **Estimación Modelo 6: ARMA(1,1)**

Dependent Variable: S3
Method: Least Squares
Date: 06/22/18 Time: 10:46
Sample (adjusted): 1980Q2 2011Q4
Included observations: 127 after adjustments
Convergence achieved after 32 iterations
MA Backcast: 1980Q1

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	4.253905	0.116770	36.42982	0.0000
AR(1)	0.726725	0.074498	9.754969	0.0000
MA(1)	0.257685	0.105239	2.448569	0.0157
R-squared	0.672571	Mean dependent var	4.254572	
Adjusted R-squared	0.667290	S.D. dependent var	0.496382	
S.E. of regression	0.286318	Akaike info criterion	0.359912	
Sum squared resid	10.16528	Schwarz criterion	0.427098	
Log likelihood	-19.85444	Hannan-Quinn criter.	0.387209	
F-statistic	127.3543	Durbin-Watson stat	1.889250	
Prob(F-statistic)	0.000000			
Inverted AR Roots	.73			
Inverted MA Roots	-.26			

Ahora, utilizando el modelo ARMA(1,1), los parámetros de ambos componentes AR y MA son significativos de forma individual y conjunta. El modelo presenta una buena bondad de ajuste, aunque parece tener problemas de autocorrelación. La combinación de los componentes AR y MA parece ser el camino a seguir.

- **Estimación Modelo 7: ARMA(2,3)**

Dependent Variable: S3
Method: Least Squares
Date: 06/22/18 Time: 10:46
Sample (adjusted): 1980Q3 2011Q4
Included observations: 126 after adjustments
Convergence achieved after 81 iterations
MA Backcast: 1979Q4 1980Q2


Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	4.248685	0.097044	43.78122	0.0000
AR(1)	-0.399123	0.153427	-2.601390	0.0105
AR(2)	0.467826	0.117277	3.989076	0.0001
MA(1)	1.523650	0.162941	9.350953	0.0000

MA(2)	0.913616	0.231967	3.938558	0.0001
MA(3)	0.292826	0.129596	2.259533	0.0257
R-squared	0.713602	Mean dependent var	4.252280	
Adjusted R-squared	0.701669	S.D. dependent var	0.497689	
S.E. of regression	0.271836	Akaike info criterion	0.279214	
Sum squared resid	8.867392	Schwarz criterion	0.414275	
Log likelihood	-11.59048	Hannan-Quinn criter.	0.334085	
F-statistic	59.79946	Durbin-Watson stat	1.996859	
Prob(F-statistic)	0.000000			
Inverted AR Roots	.51	-.91		
Inverted MA Roots	-.33-.48i	-.33+.48i	-.86	

El modelo ARMA(2,3) parece ser el modelo más indicado para explicar el comportamiento de la serie S3. Presenta parámetros significativos de forma individual y conjunta, una alta bondad de ajuste y no tiene problemas de autocorrelación.

Sus residuos parecen comportarse de forma normal, esto en base al test Jarque-Bera. Ver Gráfico 4.

GRÁFICO 4



- **Estimación Modelo 8: ARMA(3,3)**

Dependent Variable: S3
Method: Least Squares
Date: 06/22/18 Time: 11:05
Sample (adjusted): 1980Q4 2011Q4
Included observations: 125 after adjustments

Convergence achieved after 24 iterations
MA Backcast: 1980Q1 1980Q3

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	4.250647	0.110412	38.49794	0.0000
AR(1)	-0.962817	0.198673	-4.846245	0.0000
AR(2)	0.397185	0.134160	2.960542	0.0037
AR(3)	0.435803	0.146199	2.980896	0.0035
MA(1)	2.083161	0.192288	10.83357	0.0000
MA(2)	1.585868	0.259320	6.115487	0.0000
MA(3)	0.460440	0.111093	4.144655	0.0001
R-squared	0.717837	Mean dependent var	4.250124	
Adjusted R-squared	0.703490	S.D. dependent var	0.499101	
S.E. of regression	0.271774	Akaike info criterion	0.286677	
Sum squared resid	8.715595	Schwarz criterion	0.445063	
Log likelihood	-10.91733	Hannan-Quinn criter.	0.351021	
F-statistic	50.03312	Durbin-Watson stat	1.953026	
Prob(F-statistic)	0.000000			
Inverted AR Roots	.66	-.81-.10i	-.81+.10i	
Inverted MA Roots	-.61-.40i	-.61+.40i	-.87	

- **ESTIMACIÓN MODELO 9: ARMA(4,3)**

Dependent Variable: S3
Method: Least Squares
Date: 06/22/18 Time: 11:06
Sample (adjusted): 1981Q1 2011Q4
Included observations: 124 after adjustments
Convergence achieved after 25 iterations
MA Backcast: 1980Q2 1980Q4

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	4.277461	0.069882	61.20959	0.0000
AR(1)	0.603468	0.379345	1.590817	0.1144
AR(2)	0.662826	0.233882	2.834016	0.0054
AR(3)	-0.366855	0.290968	-1.260811	0.2099
AR(4)	-0.134666	0.227189	-0.592748	0.5545
MA(1)	0.480864	0.368724	1.304132	0.1948
MA(2)	-0.408544	0.317730	-1.285823	0.2011
MA(3)	-0.433904	0.175535	-2.471899	0.0149
R-squared	0.722201	Mean dependent var	4.252159	
Adjusted R-squared	0.705437	S.D. dependent var	0.500604	
S.E. of regression	0.271696	Akaike info criterion	0.294076	
Sum squared resid	8.562978	Schwarz criterion	0.476029	
Log likelihood	-10.23270	Hannan-Quinn criter.	0.367990	

F-statistic	43.08117	Durbin-Watson stat	2.009191
Prob(F-statistic)	0.000000		
Inverted AR Roots	.79-.25i	.79+.25i	-.28
Inverted MA Roots	.77	-.63+.41i	-.63-.41i

Heteroskedasticity Test: White

F-statistic	1.07E+23	Prob. F(35,92)	0.0000
Obs*R-squared	128.0000	Prob. Chi-Square(35)	0.0000
Scaled explained SS	55.39389	Prob. Chi-Square(35)	0.0155

De los modelos ARMA(3,3) y ARMA(4,3) notamos la importancia de una especificación parsimoniosa del proceso analizado. El incremento del grado del componente AR en comparación con el modelo ARMA(2,3) (el mejor modelo hasta el momento) parece ser significativo en un principio (ARMA(3,3)), pero al volver a incrementar el grado (ARMA(4,3)) esta especificación comienza a presentar problemas.

Por lo tanto seguiremos asumiendo que el mejor modelo es el ARMA(2,3).

- **Estimación Modelo 10: ARMA(2,4)**

Dependent Variable: S3
Method: Least Squares
Date: 06/22/18 Time: 10:46
Sample (adjusted): 1980Q3 2011Q4
Included observations: 126 after adjustments
Convergence achieved after 17 iterations
MA Backcast: 1979Q3 1980Q2

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	4.270901	0.064001	66.73140	0.0000
AR(1)	1.787825	0.073550	24.30758	0.0000
AR(2)	-0.906783	0.070747	-12.81718	0.0000
MA(1)	-0.761267	0.116366	-6.542028	0.0000
MA(2)	-0.146279	0.113900	-1.284280	0.2015
MA(3)	-0.165629	0.115622	-1.432503	0.1546
MA(4)	0.386707	0.106296	3.638029	0.0004
R-squared	0.720176	Mean dependent var	4.252280	
Adjusted R-squared	0.706068	S.D. dependent var	0.497689	
S.E. of regression	0.269825	Akaike info criterion	0.271864	

Sum squared resid	8.663834	Schwarz criterion	0.429435
Log likelihood	-10.12741	Hannan-Quinn criter.	0.335880
F-statistic	51.04468	Durbin-Watson stat	1.990928
Prob(F-statistic)	0.000000		
<hr/>			
Inverted AR Roots	.89-.33i	.89+.33i	
Inverted MA Roots	.81-.31i	.81+.31i	-.43+.56i -.43-.56i
<hr/>			

Heteroskedasticity Test: White

F-statistic	2.12E+22	Prob. F(44,83)	0.0000
Obs*R-squared	128.0000	Prob. Chi-Square(44)	0.0000
Scaled explained SS	58.67728	Prob. Chi-Square(44)	0.0684

Finalmente, tenemos el modelo ARMA(2,4). Este modelo presenta parámetros no significativos en sus componentes MA de mayor grado. Al igual que con el incremento de componentes AR en comparación al modelo ARMA(2,3), notamos que el incrementar el grado del componente MA ha resultado en problemas para los modelos generados.

Por lo tanto el modelo ARMA(2,3) sigue siendo el mejor modelo. Para mayor robustez, comparamos el modelo ARMA(2,3) y ARMA(2,4) y, mediante los criterios de información, volvemos a elegir al modelo ARMA(2,3) como el mejor modelo para explicar el comportamiento de la serie S3.

PASO 3: Diagnóstico

A continuación se presenta una tabla resumen que nos permitirá elegir el mejor modelo de estimación, es decir, aquel que se ajuste mejor a los datos. Tentativamente habíamos dicho que el modelo 7 ARMA(2,3) era bueno pues todos sus coeficientes eran significativos y no presentaba problemas de autocorrelación ni heterocedasticidad. Sin embargo, si utilizamos los criterios de información AIC y BIC para elegir con qué modelo quedarnos, el modelo 10


ARMA(2,4) sería más adecuado pues presenta el menor AIC. No obstante, el modelo 7 ARMA(2,3) es uno de los modelos que presenta el menor SIC.

	Akaike info criterion (AIC)	Schwarz criterion (SIC)	R-squared	Adjusted R- squared	Prob(F-statistic)
Modelo 1: ARMA(0,1)	0.78731	0.831873	0.486072	0.4819	0.000
Modelo 2: ARMA(0,3)	0.314614	0.40374	0.689515	0.682	0.000
Modelo 3: ARMA(1,0)	0.414797	0.459588	0.648608	0.6457	0.000
Modelo 4: ARMA(2,0)	0.330119	0.397649	0.683948	0.6788	0.000
Modelo 5: ARMA(3,0)	0.341943	0.432449	0.687142	0.6871	0.000
Modelo 6: ARMA(1,1)	0.359912	0.427098	0.672571	0.667	0.000
Modelo 7: ARMA(2,3)	0.279214	0.414275	0.713602	0.7016	0.000
Modelo 8: ARMA(3,3)	0.286677	0.445063	0.717837	0.7034	0.000
Modelo 9: ARMA(4,3)	0.294076	0.476029	0.722201	0.7054	0.000
Modelo 10: ARMA(2,4)	0.271864	0.429435	0.720176	0.70606	0.000

Lo que podemos concluir es que los mejores modelos de estimación son el modelo 7 y el modelo 10. En ese sentido, en la siguiente sección veremos si éstos son buenos prediciendo.

Paso 4: Predicción (opcional)


Predicción (out sample) usando el modelo 7 ARMA(2,3):



Forecast:
 SERIE3__OUTSAMPLE_ARMA23
 Actual: S3
 Forecast sample: 2011Q1 2011Q4
 Included observations: 4

Root Mean Squared Error	0.213545
Mean Absolute Error	0.185250
Mean Absolute Percentage Error	4.862415
Theil Inequality Coefficient	0.026768
Bias Proportion	0.689902
Variance Proportion	0.150047
Covariance Proportion	0.160051

Predicción (out sample) usando el modelo 10 ARMA(2,4):



Forecast:
 SERIE3__OUTSAMPLE_ARMA24
 Actual: S3
 Forecast sample: 2011Q1 2011Q4
 Included observations: 4

Root Mean Squared Error	0.508010
Mean Absolute Error	0.485662
Mean Absolute Percentage Error	12.48403
Theil Inequality Coefficient	0.061273

Bias Proportion	0.913950
Variance Proportion	0.010918
Covariance Proportion	0.075133

Tabla Resumen

Criterios	ARMA(2,3)	ARMA(2,4)
MSE	0.213545	0.50801
MAE	0.18525	0.485662
MAPE	4.862415	12.48403

En la tabla anterior, podemos ver que en términos relativos el mejor modelo para predicción es el modelo ARMA(2,3) pues presenta menores MSE, MAE y MAPE. Por tanto, este modelo debería ser utilizado para predecir la serie simulada S3.